

Межгодовой анализ изменений контента новостного портала «Правда»

www.pravda.ru

**Группа 30002
Компьютерной Лингвистики
ГИ СПбПУ**

Кирьякова Мария, Ильина Вероника

Цель

Целью исследования является изучение того, как контент онлайн-новостного портала «Правда» (<https://www.pravda.ru/>) изменился в течение трех лет.








Анализ сосредоточен на разделе общество, чтобы охарактеризовать различные аспекты периода времени.

Статьи, соответствующие периоду с 2018 по 2020 год, были извлечены с новостного интернет-портала.

Основная часть статей используется в качестве материала для анализа.

Распределение разделов по годам

Разделы по количеству документов за год.



Всего статей по годам

2024: 11984

2023: 10052

2022: 9257

2021: 15304

2020: 17778

2019: 13443

2018: 5227

Общий подход

Для проведения анализа были определены задачи:

1. Размер документов
2. Анализ словарного состава
3. Моделирование тем с использованием LSA
4. Кластеризация документов с использованием K-means
5. Кластеризация значительных лемм

Эти задачи выполняются на каждом разделе в течение разных периодов времени.


«Общество» 2018-2019-2020: Размер документов

2018 — 1562 документа

Мин. токены: 95

Макс. токены: 8587

Среднее кол-во токенов: 391




2019 — 2905 документов

Мин. токены: 37

Макс. токены: 7142

Среднее кол-во токенов: 258




2020 — 4069 документов

Мин. токены: 21

Макс. токены: 4207

Среднее кол-во токенов: 300



«Общество» 2018-2019-2020: Размер документов

Данные показывают значительные изменения в количестве статей, опубликованных в разделе “Общество” за рассматриваемый период. Наблюдается следующая динамика:

2018 год характеризуется наибольшей средней длиной статей (391 токен) и наименьшим количеством документов (1562). В 2019 году отмечается резкое увеличение количества документов (до 2905) и уменьшение среднего количества токенов на документ (258). В 2020 году количество документов продолжает увеличиваться (до 4069), среднее количество токенов на документ увеличивается на 16% (до 300), хотя максимальная длина продолжила снижаться (с 7142 токенов в 2019 г. до 4207 токенов в 2020 г.).

Выявленные тенденции могут быть обусловлены несколькими факторами:


В 2019 году портал мог изменить редакционную политику, а именно перейти на более частый, но менее детализированный контент. Тренд на сокращение внимания пользователей мог подтолкнуть редакцию к укорочению материалов для повышения вовлеченности.

В 2020 году умеренный рост средней длины статьи может быть связан с необходимостью более глубокого освещения сложных тем, таких как пандемия COVID-19.

«Общество» 2018-2019-2020: Анализ словарного состава


2018 — Всего лемм: 318607
 Уникальные леммы: 34475
 Отношение: 0.11

Топ-30 самых частых токенов




2019 — Всего лемм: 403351
 Уникальные леммы: 35818
 Отношение: 0.09

Топ-30 самых частых токенов



2020 — Всего лемм: 612812
 Уникальные леммы: 50857
 Отношение: 0.08

Топ-30 самых частых токенов



«Общество» 2018-2019-2020: Анализ словарного состава

В **2018 году** в топе наблюдаются леммы, связанные с обществом и государством: «год», «человек», «россия», «страна», «право», «ребёнок», «новый». *Эти слова свидетельствуют о фокусе на временных аспектах, людях и российской повестке.*

В **2019 году** в топ входят леммы «год», «россия», «человек», «слово», «ребёнок», «работа», «земля», «право», «дело». Здесь появляются слова, связанные с работой и юридической сферой («дело», «право», «земля»), что *указывает на смещение внимания в сторону экономических и правовых вопросов.*

В **2020 году** в топе сохраняются ключевые слова «человек», «россия», «год», «время», «работа», «слово», «российский». Также появляются такие термины, как «ситуация», «гражданин», «право», «первый», что *говорит о более акцентированном внимании на социальных ситуациях и гражданстве, вероятно, обусловленных актуальными событиями того периода.* Необходимо отметить, что появляется лемма «коронавирус», *это может быть связано с пандемией COVID-19.*

Общее количество лемм существенно растёт год от года, что свидетельствует либо о возрастании объёма текстов, либо о более насыщенном содержании. Количество уникальных лемм также увеличивается, но отношение уникальных лемм к общему числу снижается (с 0.11 до 0.08), что *указывает на некоторое снижение лексического разнообразия, возможно из-за повторяющихся тематик или закрепления ключевых терминов.*

«Общество» 2018-2019-2020: Моделирование тем с LSA

2018 — 5 тем, 10 терминов

Topic 1: год, россия, человек, пенсионный, российский, россиянин, страна, ребёнок, возраст, пенсия

Topic 2: пенсионный, пенсия, реформа, возраст, повышение, пенсионер, правительство, народ, 65, выход

Topic 3: ребёнок, пенсионный, человек, женщина, возраст, родитель, школа, пенсия, мужчина, семья

Topic 4: россиянин, год, опросить, опрос, респондент, исследование, процент, страна, жизнь, социолог

Topic 5: ребёнок, путин, президент, владимир, школа, родитель, пожар, семья, опросить, опрос

2019 — 5 тем, 10 терминов

Topic 1: год, россия, человек, ребёнок, россиянин, российский, тысяча, страна, рубль, работа

Topic 2: россиянин, опросить, опрос, респондент, год, исследование, социолог, пенсия, гражданин, провести

Topic 3: рубль, пенсия, тысяча, пенсионный, год, размер, пенсионер, выплата, суд, штраф

Topic 4: ребёнок, пенсия, школа, пенсионный, родитель, образование, год, семья, возраст, учитель

Topic 5: пенсия, пенсионный, человек, путин, пенсионер, фонд, женщина, владимир, президент, разведчик

2020 — 5 тем, 10 терминов

Topic 1: человек, год, россия, ребёнок, страна, коронавирус, время, работа, говорить, тысяча

Topic 2: рубль, тысяча, выплата, пенсия, год, пособие, пенсионный, размер, россиянин, пенсионер

Topic 3: ребёнок, семья, родитель, школа, выплата, женщина, год, пенсия, пособие, образование

Topic 4: школа, егэ, обучение, образование, экзамен, дистанционный, ребёнок, учебный, школьник, коронавирус

Topic 5: ребёнок, коронавирус, человек, врач, covid, семья, 19, маска, заражение, заболевание

«Общество» 2018-2019-2020: Моделирование тем с LSA

На основе представленных результатов LSA можно выделить следующие ключевые темы, присутствующие в разделе “Общество” за 2018–2020 годы:

С 2018 по 2019 год ключевой темой была пенсионная реформа (слова “пенсионный”, “пенсия”, “реформа”, “возраст”, “повышение” есть как в топиках 2018 года, так и 2019).

В топике 2018 года есть термин “пожар”, что можно связать с пожаром в торгово-развлекательном комплексе “Зимняя вишня” в городе Кемерово, и слова “Путин”, “президент”, “Владимир”, что может быть связано с президентскими выборами в России.

В 2020 году фокус внимания сместился на тему пандемии коронавируса и мер, введенных из-за неё: дистанционное обучение, масочный режим и т.д., но тема пенсии сохранялась на протяжении всего периода. Также можно заметить термины “выплата”, “пособие”, “ребенок”, что может быть связано с единовременной выплатой 10 тысяч рублей семьям с детьми в 2020 году.


Причины:

- Пенсионная реформа (2018–2019) – активное обсуждение повышения пенсионного возраста (до 65 и 60 лет для мужчин и женщин соответственно);
- Политическая повестка (2018) – президентские выборы;
- Чрезвычайные события (2018) – трагедия в Кемерово, потрясшая всю страну;
- Социальная поддержка (2020) – обсуждение единовременной выплаты от президента для всех школьников;
- Пандемия COVID-19 (2020) – редакция сместила фокус на освещение этой темы, поскольку она явилась глобальной проблемой, повлиявшей на все сферы жизни общества.

«Общество» 2018-2019-2020: Кластеризация документов с K-means


2018 — 3 кластера

Кластеры K-средних




2019 — 3 кластера

Кластеры K-средних



2020 — 3 кластера

Кластеры K-средних



«Общество» 2018-2019-2020: Кластеризация документов с K-means

2018 год (3 кластера):

- Кластеры отчетливо разделены на визуализации, что *говорит о хорошей интерпретируемости и тематической разнородности групп.*
- Можно предположить, что каждый кластер *отражает определенные подкатегории внутри тематики «Общество»* (например, образование и медицина).
- Кластеры достаточно компактны, что говорит об *однородности внутри групп.*

2019 год (3 кластера):


- Кластеры начали перекрываться сильнее, что *может указывать на приближение тем в разных группах.*
- Выделяются четкие центры кластеров, что *свидетельствует о выделении заметных подкатегорий,* возможно с более сложными взаимосвязями.
- Кластеры более растянуты, что требует дополнительного анализа содержания для уточнения смысловых границ.

2020 год (3 кластера):


- Кластеры визуально хорошо отделены, однако некоторые группы имеют более высокую плотность.
- Распределение может отражать более ярко выраженные подкатегории с четко выраженной тематической спецификой, например, *внимание к новым социальным ситуациям,* вызванным внешними факторами (пандемия COVID-19, социально-политические изменения).
- Высокая плотность некоторых кластеров может говорить о *концентрации статей вокруг ключевых подтем.*

«Общество» 2018-2019-2020: Кластеризация лемм


2018 — 12 лемм



2019 — 12 лемм



2020 — 12 лемм



«Общество» 2018-2019-2020: Кластеризация лемм

В **2018 году** леммы разделяются на несколько относительно плотных групп. Например, «семья», «родитель», «ребёнок» и «человек» образуют один кластер, *связанный с семейными и социальными аспектами*. Леммы «пенсия», «пенсионер», «выплата» формируют ещё один кластер, *связанный с социальной поддержкой и выплатами*.

В **2019 году** наблюдается другая группировка: «возраст», «пенсия» и «выплата» образуют близко расположенный кластер, *демонстрируя связь социальной поддержки для пожилых людей*. Леммы «работа», «учитель», «школа», «семья», «родитель», «ребёнок» образуют более разветвленную группу, *связанную с образовательной и семейной тематикой*.

В **2020 году** кластеры стали более компактными: «пенсия», «пенсионер», «возраст», «выплата» формируют плотный кластер, что указывает на *усиленную связь тем социальной поддержки пожилых людей*. Группа с «школа», «учитель», «работа» и «человек» расположена отдельно, *обозначая сферу образования и труда*, а «семья», «родитель», «ребёнок» — *семейно-детскую тематику*.

«Общество» 2018-2019-2020: Кластеризация лемм

«Возраст», «пенсия», «пенсионер» и «выплата» тесно связаны в течение всех трёх лет, что *отражает устойчивую тематику социальной защиты пожилых граждан.*

Семейные леммы «семья», «родитель», «ребёнок» постоянно формируют отдельный кластер, который *связан с социальной и семейной тематикой.*

Лемма «работа» занимает промежуточное или отдельное положение, что *подразумевает экономическую или трудовую составляющую общества,* при этом её связь с другими леммами меняется в разные годы.

В **2018 году** кластеры представлены более размыто, с большим распределением лемм по семантическому пространству, что *может отражать менее выраженное разделение тем.*

В **2019 году** наблюдается появление более чётких кластеров, а «возраст», «пенсия», «пенсионер» и «выплата» теснее связаны, что *может означать усиление внимания к социальной политике данного периода.*

В **2020 году** кластеры становятся наиболее чёткими, особенно выделяется плотный кластер *социального обеспечения пожилых граждан.* Это может указывать на изменение общественного дискурса, связанного с социально-экономической поддержкой.

Выводы

1. Размер документов

Портал перешел к модели более частых, но менее детализированных публикаций, что соответствует современным трендам цифровой журналистики на оперативность и лаконичность.

2. Анализ словарного состава

Анализ показывает динамику в тематике обсуждений слова «общество» за три года: от фокусировки на базовых понятиях и временных аспектах в 2018 году, через усиление внимания к экономическим и правовым вопросам в 2019-м, к акценту на социальные ситуации и гражданскую позицию в 2020-м. Эти изменения отражают влияние как внутренней политической повестки, так и внешних обстоятельств, что подтверждает адекватность выбранных лемм для описания общественно значимых процессов.

3. Моделирование тем с LSA

Тематический фокус последовательно смещался с пенсионной реформы (2018-2019) на пандемию COVID-19 (2020), демонстрируя чуткость портала к наиболее актуальным общественным проблемам.

4. Кластеризация документов с K-means

Общая динамика показывает, что со временем тематика становится более сложной и взаимосвязанной, что требует использования дополнительных методов анализа для точного выделения смысловых границ и подкатегорий.

5. Кластеризация лемм

Семантический анализ лемм показывает устойчивое выделение ключевых областей: социальная поддержка (пенсия, возраст, выплаты), семейные отношения (семья, родитель, ребёнок) и трудовая деятельность (работа, школа, учитель). Между годами наблюдаются как стабильные связи, так и изменения, отражающие развитие общественного дискурса.

Контент портала демонстрирует баланс между оперативным реагированием на актуальные события и сохранением устойчивых тематических направлений, что отражает как редакционную политику, так и изменения в общественных запросах.

Библиография

Bird, S., Klein, E., & Loper, E. (2009). Natural language processing with Python: Analyzing text with the Natural Language Toolkit. O'Reilly Media.

Honnibal, M., & Montani, I. (2016). spaCy: Industrial-strength natural language processing in Python. In Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing (EMNLP). Austin, Texas: ACL. <https://spacy.io/>

Jurafsky, D., & Martin, J. H. (2025). Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition (3rd ed. draft). Retrieved from <https://web.stanford.edu/~jurafsky/slp3/>

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. arXiv

Řehůřek, R., & Sojka, P. (2010). Software framework for topic modelling with large corpora. In Proceedings of the LREC 2010 Workshop on New Challenges for NLP Frameworks (pp. 45–50). Valletta, Malta: ELRA. <http://is.muni.cz/publication/884893/en>

Ресурсы

Google Colab: Cloud-based platform for running Jupyter notebooks.

Pandas: Data manipulation

Matplotlib: Data visualization

NLTK: Tokenization - <https://www.nltk.org/>

spaCy: tokenization and lemmatization - <https://spacy.io/>

Scikit-learn: Clustering and dimensionality reduction - <https://scikit-learn.org/>

Gensim: Topic modeling and word embeddings - <https://radimrehurek.com/gensim/>

Участники

Раздел Политика, период 2018-2019; 2019-2020
Раздел Политика, период 2020-2021; 2021-2022
Раздел Политика, период 2022-2023; 2023-2024
Раздел Экономика, период 2018-2019; 2019-2020
Раздел Экономика, период 2020-2021; 2021-2022
Раздел Экономика, период 2022-2023; 2023-2024
Раздел Культура, период 2018-2019; 2019-2020
Раздел Культура, период 2020-2021; 2021-2022
Раздел Культура, период 2022-2023; 2023-2024
Раздел Спорт, период 2018-2019; 2019-2020
Раздел Спорт, период 2020-2021; 2021-2022
Раздел Спорт, период 2022-2023; 2023-2024
Раздел Здоровье, период 2018-2019; 2019-2020
Раздел Здоровье, период 2020-2021; 2021-2022
Раздел Здоровье, период 2022-2023; 2023-2024
Раздел Наука, период 2018-2019; 2019-2020
Раздел Наука, период 2020-2021; 2021-2022
Раздел Наука, период 2022-2023; 2023-2024
Раздел Общество, период 2018-2019; 2019-2020: все участники
Раздел Общество, период 2020-2021; 2021-2022
Раздел Общество, период 2022-2023; 2023-2024